

מהפכת ה-AI בחומרה

איך באמת עובד המחשב? מטרנזיסטורים בודדים, דרך מעבדים, ועד לחוות השרתים המאמנות את ה-LLMs הבאים.

ההבדל בין CPU ל- GPU

600×400

- **מעבד (CPU):** מעבד נתונים בטור (אחד אחרי השני). פשוט ולעניין.
- **כרטיס מסך (GPU):** מעבד נתונים במקביל (המון ביחד).
- זהו, תכל'ס זה כל מה שאתם צריכים לדעת על למה AI עובד מהר. קל, נכון?

שאלות ותשובות

תודה רבה על ההקשבה! מקווה שהכל מובן.



ברור שזה לא כזה פשוט. עכשיו נתחיל באמת לצלול לקרביים של המערכות ונגלה
מה מסתתר מאחורי הקלעים.

המנהל מול צבא הפועלים: Latency לעומת Throughput

ה-GPU: "צבא הפועלים"

ה-GPU מתוכנן ל-**Throughput** גבוה. המטרה: לבצע מיליוני משימות קטנות במקביל. במקום 16 עובדים חכמים, ה-GPU מביא 10,000 עובדים פשוטים שעושים בדיוק את אותה פעולה שוב ושוב.

ה-CPU: "המנהל הכללי"

ה-CPU מתוכנן ל-**Latency** נמוך. המטרה: לסיים משימה מסובכת אחת מהר ככל האפשר. מריץ מערכת הפעלה, מטפל ברשת, פותח קבצים. יש לו מספר קטן של ליבות "כבדות", חכמות ומהירות מאוד שיודעות לקבל החלטות.

אז מה באמת קורה בתוך המחשב? (ליבת CPU)



Out of Order

המעבד יודע לסדר מחדש פקודות תוך כדי תנועה (Out of order execution) כדי למנוע צווארי בקבוק ולסיים את הלוגיקה והגישה לזיכרון במינימום זמן.



Branch Prediction

תנאי (if) עוצר את העבודה. ה-CPU לא מחכה! הוא מנחש את המסלול מראש. אם הוא צדק - חסכנו זמן, אם טעה - מבטלים. מושלים לתוכנות קונבנציונליות.



לוגיקה ו-ALU

בסוף הכל זה שערים לוגיים וטרנזיסטורים. יחידת ה-ALU מבצעת מתמטיקה. אבל רוב הסיליקון מוקדש ללוגיקה, זיכרון (Registers, L1/L2 Caches) וקבלת החלטות.

מה AI מבקש מהמחשב שלנו?

AI זה רק מתמטיקה עצומה

רשתות נוירונים לא צריכות "הסתעפויות". הנוירון מקבל קלטים (x) ומכפיל אותם במשקלים (w). בפועל, זו **מכפלת מטריצות (Matrix Multiplication)** ענקית.

כשמכפילים מטריצה של 4096×4096 , התאים לא תלויים זה בזה ואפשר לבצע הכל במקביל. וכאן ה-GPU זוהר.

+17B

פעולות כפל לפעולה אחת

הסוד של ה-GPU: ארכיטקטורת SIMT ו-Tensor Cores

Single Instruction, Multiple Threads

ה-GPU מכיל עשרות Streaming Multiprocessors (SM). כל SM מחלק את העבודה לאלפי נימים (Threads). המודל נקרא SIMT - כולם מבצעים את **אותה הפקודה על נתונים שונים**. אם יש "If/Else" שונה לכל נימ, ה-GPU יאבד את היתרון שלו (Branch Divergence).

$$D = A \times B + C$$

כדי להתמודד עם זה פותחו ה-**Tensor Cores** - יחידות חומרה ייעודיות שיוצרות לבצע פעולת כפל-חיבור של מטריצה שלמה במחזור שעון אחד (Multiply-Accumulate).



למה אנחנו משתמשים ב-FP16 ו-FP8?

CPU קונבנציונלי עובד לרוב ב-32 או 64 ביט. ב-AI, הדיוק הזה מיותר וגוזל משאבים אדירים.

סוג משתנה	כמות זיכרון למספר	השפעה על רוחב פס (Bandwidth)	שימוש אופייני ב-AI
FP32 (Single Precision)	Bits 32	גבוה מאוד (צוואר בקבוק)	שמירת משקלים קריטיים (Master Weights)
FP16 / BF16	Bits 16	פי 2 מהיר יותר מ-32 ביט	אימון מודלים מודרניים (Mixed Precision)
FP8 / INT8	Bits 8	מהירות עצומה, פחות דיוק	Inference (הרצת המודל בפועל) וקוונטיזציה
FP4	Bits 4	יעילות קצה (Edge)	מודלים זעירים לטלפונים ניידים

איך זה מתחבר ל-ChatGPT? מאימון להסקה (Inference)

שלב ההסקה (Inference) - צמא לזיכרון

כאן ה-LLM מנחש את המילה (Token) הבאה. רוב ארכיטקטורת ה-Transformer (Attention, W_q , W_k , W_v , MLP) כבולה למהירות הזיכרון ולא לכוח החישוב! יש צורך לקרוא משקלים אדירים מהזיכרון בכל צעד.

שלב האימון (Training) - צמא לכוח

מורכב מ-Forward Pass (חיזוי) ו-Backpropagation (תיקון שגיאה). הכל מתורגם למכפלת מטריצות. השלב הזה דורש אשכולות עצומים של אלפי GPU שמבצעים במקביל, Data, Tensor, ו-Pipeline Parallelism כדי לחשב gradients.

כשה-GPU יושב ומחכה: בעיית התקשורת



- GPU אחד זה קל. אבל כשמאמנים מודל על 10,000 כרטיסים, החומרה חייבת לדבר.
- אם GPU #1 מסיים לחשב ומחכה ל-GPU #2, אנחנו שורפים מיליוני דולרים של חשמל לחינם.
- כאן נכנסת טכנולוגיית התקשורת: **NVLink** ומתגי **NVSwitch** שמאפשרים תעבורה פנימית אדירה בתוך השרת.
- צוואר בקבוק נוסף הוא הזיכרון. GPU דורש זיכרון מיוחד ויקר שנקרא **HBM (High Bandwidth Memory)** שממוקם פיזית באותו המארז יחד עם הליבה כדי לחסוך זמן טיסה לחשמל.

למה NVIDIA שולטת? (חומת המגן של CUDA)

 **מעטפת ה-NVIDIA: CUDA** לא רק בונה סיליקון. CUDA היא פלטפורמת התוכנה המאפשרת למפתחים לגשת ל-GPU בקלות. מיליוני שורות קוד נכתבו מעליה ואי אפשר פשוט להעביר אותן למעבד מתחרה.

 **אופטימיזציה ל-Frameworks:** ספריות כמו TensorFlow ו-PyTorch עברו עשור של התאמות ייעודיות לרוץ בצורה מושלמת על ארכיטקטורת NVIDIA. זהו Lock-in עצום.

 **מערכת שלמה (Systems Company):** התחרות היום היא לא על "למי יש צ'יפ יותר מהיר". השאלה היא למי יש את התשתית - כרטיסי הרשת (Mellanox לשעבר), המתגים, והתוכנה לנהל אלפי שרתים יחד (NCCL).



צווארי הבקבוק הפיזיים

מה עוצר בעדנו מלאמן את GPT-6 כבר מחר בבוקר?

חשמל: חוות שרתים ל-AI דורשות כמות חשמל המקבילה לעיר בינונית. אי אפשר להקים אותן בכל מקום.

קירור: הסיליקון רותח. אנו עוברים מקירור אוויר לקירור נוזלי (Liquid Cooling) מורכב ויקר.

ייצור ושרשראות אספקה: הכל תלוי בחברות ספורות - ASML (מכונות הליתוגרפיה היחידות בעולם), ו-TSMC מטייוואן שיודעת לייצר ולארוז את הסיליקון בשיטות מורכבות כמו CoWoS.

שאלות?

עכשיו באמת, תודה רבה על ההאזנה.

חומרות, רשתות ועיבוד מקבילי • AI Architecture

Image Sources

https://img.magnific.com/premium-vector/futuristic-ai-chip-processor-with-glowing-circuit-background-technology-vector-design_1280668-3144.jpg?semt=ais_hybrid&w=740&q=80

Source: www.magnific.com



<https://images.stockcake.com/public/a/5/e/a5e8d5ad-628f-495e-8872-e3ad669937e0/silicon-wafer-manufacturing-stockcake.jpg>

Source: stockcake.com



https://images.stockcake.com/public/a/a/d/aad7a1c5-b6ac-4db6-84e0-754811edb245_medium/digital-server-infrastructure-stockcake.jpg

Source: stockcake.com

